



# Extraer texto de documentos PDF

Recordemos que, en la actualidad, Python es un lenguaje muy popular, y muchas tareas que podamos necesitar ya están implementadas en bibliotecas para que podamos utilizarlas con mayor facilidad, por lo anterior, revisaremos la extracción de texto con tres bibliotecas utilizando *script* de Python y utilizando Google Colab como ambiente de programación.

## Extracción de texto con PyPDF

Primero, veamos cómo llevar a cabo esta tarea usando **pypdf**, una librería de código abierto que precisamente nos permite trabajar con archivos PDF. Lo primero que tenemos que hacer para poder trabajar con esta librería es instalarla, para ello podemos ejecutar el siguiente comando:

```
!pip install pypdf
```

El siguiente paso, es importar `PdfReader` para poder leer el archivo PDF de entrada:

```
from pypdf import PdfReader
```

Para este ejemplo, trabajaremos con un archivo muy simple que contiene puro texto denominado “sample”, mismo que encontrarás en los archivos adjuntos de la plataforma, toma en cuenta que este archivo fue precargado en los archivos temporales de Google Colab, tomando en cuenta su localización, lo siguiente que haremos es leer el archivo usando la siguiente instrucción.

```
reader = PdfReader("sample.pdf")
```

Extraeremos la única página con la que cuenta el PDF en una variable llamada `page`.

```
page = reader.pages[0]
```

En seguida, utilizaremos la función `extract_text()` para obtener el texto de esta página y lo imprimimos en la pantalla.

```
print(page.extract_text())
```

### Salida:

Sample PDFThis is a simple PDF file. Fun fun fun.

Lorem ipsum dolor sit amet, consectetur adipiscing elit.  
Phasellus facilisis odio sed mi.

Curabitur suscipit. Nullam vel nisi. Etiam semper ipsum ut  
lectus. Proin aliquam, erat eget

pharetra commodo, eros mi condimentum quam, sed commodo justo  
quam ut velit.

Integer a erat. Cras laoreet ligula cursus enim. Aenean scelerisque  
velit et tellus.

Vestibulum dictum aliquet sem. Nulla facilisi. Vestibulum  
accumsan ante vitae elit. Nulla

erat dolor, blandit in, rutrum quis, semper pulvinar, enim.  
Nullam varius congue risus.

Vivamus sollicitudin, metus ut interdum eleifend, nisi tellus  
pellentesque elit, tristique

accumsan eros quam et risus. Suspendisse libero odio, mattis sit amet, aliquet eget,

hendrerit vel, nulla. Sed vitae augue. Aliquam erat volutpat. Aliquam feugiat vulputate nisl.

Suspendisse quis nulla pretium ante pretium mollis. Proin velit ligula, sagittis at, egestas a,

pulvinar quis, nisl.

Pellentesque sit amet lectus. Praesent pulvinar, nunc quis iaculis sagittis, justo quam

lobortis tortor, sed vestibulum dui metus venenatis est. Nunc cursus ligula. Nulla facilisi.

Phasellus ullamcorper consectetur ante. Duis tincidunt, urna id condimentum luctus, nibh

ante vulputate sapien, id sagittis massa orci ut enim. Pellentesque vestibulum convallis

sem. Nulla consequat quam ut nisl. Nullam est. Curabitur tincidunt dapibus lorem. Proin

velit turpis, scelerisque sit amet, iaculis nec, rhoncus ac, ipsum. Phasellus lorem arcu,

feugiat eu, gravida eu, consequat molestie, ipsum. Nullam vel est ut ipsum volutpat

feugiat. Aenean pellentesque.

In mauris. Pellentesque dui nisi, iaculis eu, rhoncus in, venenatis ac, ante. Ut odio justo,

scelerisque vel, facilisis non, commodo a, pede. Cras nec massa sit amet tortor volutpat

varius. Donec lacinia, neque a luctus aliquet, pede massa imperdiet ante, at varius lorem

pede sed sapien. Fusce erat nibh, aliquet in, eleifend eget, commodo eget, erat. Fusce

consectetur. Cras risus tortor, porttitor nec, tristique sed, convallis semper, eros. Fusce

vulputate ipsum a mauris. Phasellus mollis. Curabitur sed urna. Aliquam nec sapien non

nibh pulvinar convallis. Vivamus facilisis augue quis quam. Proin cursus aliquet metus.

Suspendisse lacinia. Nulla at tellus ac turpis eleifend scelerisque. Maecenas a pede vitae

enim commodo interdum. Donec odio. Sed sollicitudin dui vitae justo.

Morbi elit nunc, facilisis a, mollis a, molestie at, lectus. Suspendisse eget mauris eu tellus

molestie cursus. Duis ut magna at justo dignissim condimentum. Cum sociis natoque

penatibus et magnis dis parturient montes, nascetur ridiculus mus. Vivamus varius. Ut sit

amet diam suscipit mauris ornare aliquam. Sed varius. Duis arcu. Etiam tristique massa

eget dui. Phasellus congue. Aenean est erat, tincidunt eget, venenatis quis, commodo at,

quam.

Ahora que es posible visualizar el resultado, es necesario mencionar que este archivo está muy bien estructurado y contiene puro texto, si probamos estas instrucciones con otro archivo que contenga, por ejemplo, varios tipos de letra, imágenes, tablas, y otro tipo de información, el resultado no será tan eficiente. Ejemplo de esto, tenemos el PDF “ficha\_A\_A1”, el cual consiste en una ficha técnica de un automóvil, recordándote que podrás descargarla desde los archivos adjuntos.

```
reader = PdfReader("ficha_A_A1.pdf")
```

```
page = reader.pages[0]
```

```
print(page.extract_text())
```

Una vez que aplicamos las instrucciones anteriores para este archivo, tendremos una salida similar a lo siguiente:

Ficha técnica

A1 Sportback 2024

Motorización A1 SB 35 TFSI Ego A1 SB 40 TFSI S line

Cilindrada 1.5 L (1,498 cm<sup>3</sup>) 2.0 L (1,984 cm<sup>3</sup>)

Motor 4 cil. en línea, TFSI 4 cil. en línea, TFSI

Potencia 150 hp / 5,000- 6,000 rpm 200 hp / 4,400-6,000 rpm

Torque 250 Nm / 1,500 -3,500 rpm 320 Nm/1,500 - 4,400 rpm

Tracción delantera delantera

Transmisión S tronic 7 Vel. S tronic 6 Vel.

Velocidad máxima 222 km/ hr 235km/hr

Aceleración 0-100 km/hr 7.7 s 6.5 s

Rendimiento de combustible (ciudad / carretera / combinado) 14.8/ 20.6/ 16.9 km/l 13.7/ 19.4/ 15.8 km/l

Norma de emisión de gases EU6 EU6

Emisiones de CO<sub>2</sub> (ciudad / carretera / combinado) 159.1/ 114.0/ 138.8 gCO<sub>2</sub>/km 171.2/ 121.2/ 148.7 gCO<sub>2</sub>/km

Dimensiones Largo 4029 mm 4029 mm

Ancho 1740 mm 1740 mm

Alto 1433 mm 1433 mm

Distancia entre ejes 2563 mm 2563 mm

Peso en vacío (con conductor) 1,240 kg 1,335 kg

Capacidad del maletero 335 l 335 l

Capacidad del tanque de combustible 40 l 40 l

Número de puertas 5 5

.....  
.....

1.0 L (999 cm<sup>3</sup>)

3 cil. en línea, TFSI

116 hp / 5,000 -5,500 rpm

S tronic 7 Vel.

203 km/hr

A1

**Nota:** Código recortado para fines prácticos.



## Extracción de texto con PyMuPDF

PyPDF no es la única biblioteca que puede ser útil para estos fines, PyMuPDF es una herramienta que trabaja de manera muy similar, para hacer uso de la misma primero instalamos la biblioteca, además de realizar los *imports* necesarios.

```
!pip install PyMuPDF
import pymupdf
print(pymupdf.__doc__)
```

Enseguida abrimos el documento, en este caso reutilizaremos el PDF “sample”.

```
doc = pymupdf.open("sample.pdf")
```

Cargaremos la página de nuestro interés, en este caso, recordemos que solo consta de una, por lo que colocamos 0, tal como los índices de Python.

```
page = doc.load_page(0)
```

Finalmente, extraemos el texto y lo mandamos a imprimir.

```
print(page.get_text())
```

**Salida:**

```
Sample PDF
```

```
This is a simple PDF file. Fun fun fun.
```

```
Lorem ipsum dolor sit amet, consectetur adipiscing elit.
```

Phasellus facilisis odio sed mi.

Curabitur suscipit. Nullam vel nisi. Etiam semper ipsum ut lectus. Proin aliquam, erat eget

pharetra commodo, eros mi condimentum quam, sed commodo justo quam ut velit.

Integer a erat. Cras laoreet ligula cursus enim. Aenean scelerisque velit et tellus.

Vestibulum dictum aliquet sem. Nulla facilisi. Vestibulum accumsan ante vitae elit. Nulla

erat dolor, blandit in, rutrum quis, semper pulvinar, enim. Nullam varius congue risus.

Vivamus sollicitudin, metus ut interdum eleifend, nisi tellus pellentesque elit, tristique

accumsan eros quam et risus. Suspendisse libero odio, mattis sit amet, aliquet eget,

hendrerit vel, nulla. Sed vitae augue. Aliquam erat volutpat. Aliquam feugiat vulputate nisl.

Suspendisse quis nulla pretium ante pretium mollis. Proin velit ligula, sagittis at, egestas a,

pulvinar quis, nisl.

Pellentesque sit amet lectus. Praesent pulvinar, nunc quis iaculis sagittis, justo quam

lobortis tortor, sed vestibulum dui metus venenatis est.  
Nunc cursus ligula. Nulla facilisi.

Phasellus ullamcorper consectetur ante. Duis tincidunt,  
urna id condimentum luctus, nibh

ante vulputate sapien, id sagittis massa orci ut enim. Pellentesque vestibulum convallis

sem. Nulla consequat quam ut nisl. Nullam est. Curabitur  
tincidunt dapibus lorem. Proin

velit turpis, scelerisque sit amet, iaculis nec, rhoncus ac,  
ipsum. Phasellus lorem arcu,

feugiat eu, gravida eu, consequat molestie, ipsum. Nullam  
vel est ut ipsum volutpat

feugiat. Aenean pellentesque.

In mauris. Pellentesque dui nisi, iaculis eu, rhoncus in,  
venenatis ac, ante. Ut odio justo,

scelerisque vel, facilisis non, commodo a, pede. Cras nec  
massa sit amet tortor volutpat

varius. Donec lacinia, neque a luctus aliquet, pede massa  
imperdiet ante, at varius lorem

pede sed sapien. Fusce erat nibh, aliquet in, eleifend eget,  
commodo eget, erat. Fusce

consectetur. Cras risus tortor, porttitor nec, tristique  
sed, convallis semper, eros. Fusce

vulputate ipsum a mauris. Phasellus mollis. Curabitur sed urna. Aliquam nec sapien non

nibh pulvinar convallis. Vivamus facilisis augue quis quam. Proin cursus aliquet metus.

Suspendisse lacinia. Nulla at tellus ac turpis eleifend scelerisque. Maecenas a pede vitae

enim commodo interdum. Donec odio. Sed sollicitudin dui vitae justo.

Morbi elit nunc, facilisis a, mollis a, molestie at, lectus. Suspendisse eget mauris eu tellus

molestie cursus. Duis ut magna at justo dignissim condimentum. Cum sociis natoque

penatibus et magnis dis parturient montes, nascetur ridiculus mus. Vivamus varius. Ut sit

amet diam suscipit mauris ornare aliquam. Sed varius. Duis arcu. Etiam tristique massa

eget dui. Phasellus congue. Aenean est erat, tincidunt eget, venenatis quis, commodo at,

quam.

Con lo anterior podemos observar que el resultado es muy similar a nuestro primer ejemplo donde se utilizó pypdf.

## PdfReader (pypdf)

```
Comandos + Código + Texto Ejecutar todas
reader = PdfReader("sample.pdf")

[16] page = reader.pages[0]

[17] print(page.extract_text())

Sample PDF
This is a simple PDF file. Fun fun fun.
Lorem ipsum dolor sit amet, consectetur adipiscing elit. Phasellus facilisis odio sed mi.
Curabitur suscipit. Nullam vel nisi. Etiam semper ipsum ut lectus. Proin aliquam, erat eget
pharetra commodo, eros mi condimentum quam, sed commodo justo quam ut velit.
Integer a erat. Cras laoreet ligula cursus enim. Aenean scelerisque velit et tellus.
Vestibulum dictum aliquet sem. Nulla facilisi. Vestibulum accumsan ante vitae elit. Nulla
erat dolor, blandit in, rutrum quis, semper pulvinar, enim. Nullam varius congue risus.
Vivamus sollicitudin, metus ut interdum eleifend, nisi tellus pellentesque elit, tristique
accumsan eros quam et risus. Suspendisse libero odio, mattis sit amet, aliquet eget,
hendrerit vel, nulla. Sed vitae augue. Aliquam erat volutpat. Aliquam feugiat vulputate nisl.
Suspendisse quis nulla pretium ante pretium mollis. Proin velit ligula, sagittis at, egestas a,
pulvinar quis, nisl.
Pellentesque sit amet lectus. Praesent pulvinar, nunc quis iaculis sagittis, justo quam
lobortis tortor, sed vestibulum dui metus venenatis est. Nunc cursus ligula. Nulla facilisi.
Phasellus ullamcorper consectetur ante. Duis tincidunt, urna id condimentum luctus, nibh
ante vulputate sapien, id sagittis massa orci ut enim. Pellentesque vestibulum convallis
sem. Nulla consequat quam ut nisl. Nullam est. Curabitur tincidunt dapibus lorem. Proin
velit turpis, scelerisque sit amet, iaculis nec, rhoncus ac, ipsum. Phasellus lorem arcu,
feugiat eu, gravida eu, consequat molestie, ipsum. Nullam vel est ut ipsum volutpat
feugiat. Aenean pellentesque.
In mauris. Pellentesque dui nisl, iaculis eu, rhoncus in, venenatis ac, ante. Ut odio justo,
scelerisque vel, facilisis non, commodo a, pede. Cras nec massa sit amet tortor volutpat
varius. Donec lacinia, neque a luctus aliquet, pede massa imperdiet ante, at varius lorem
pede sed sapien. Fusce erat nibh, aliquet in, eleifend eget, commodo eget, erat. Fusce
consectetur. Cras risus tortor, porttitor nec, convallis semper, eros. Fusce
volutate ipsum a mauris. Phasellus mollis. Curabitur sed urna. Aliquam nec sapien non
nibh pulvinar convallis. Vivamus facilisis augue quis quam. Proin cursus aliquet metus.
Suspendisse lacinia. Nulla at tellus ac turpis eleifend scelerisque. Maecenas a pede vitae
enim commodo interdum. Donec odio. Sed sollicitudin dui vitae justo.
Morbi elit nunc, facilisis a, mollis a, molestie at, lectus. Suspendisse eget mauris eu tellus
molestie cursus. Duis ut magna at justo dignissim condimentum. Cum sociis natoque
penatibus et magnis dis parturient montes, nascetur ridiculus mus. Vivamus varius. Ut sit
amet diam suscipit mauris ornare aliquam. Sed varius. Duis arcu. Etiam tristique massa
eget dui. Phasellus congue. Aenean est erat, tincidunt eget, venenatis quis, commodo at,
quam.
```

## pymupdf

```
Comandos + Código + Texto Ejecutar todas
[42] doc = pymupdf.open("sample.pdf")

[37] page = doc.load_page(0)

[38] print(page.get_text())

Sample PDF
This is a simple PDF file. Fun fun fun.
Lorem ipsum dolor sit amet, consectetur adipiscing elit. Phasellus facilisis odio sed mi.
Curabitur suscipit. Nullam vel nisi. Etiam semper ipsum ut lectus. Proin aliquam, erat eget
pharetra commodo, eros mi condimentum quam, sed commodo justo quam ut velit.
Integer a erat. Cras laoreet ligula cursus enim. Aenean scelerisque velit et tellus.
Vestibulum dictum aliquet sem. Nulla facilisi. Vestibulum accumsan ante vitae elit. Nulla
erat dolor, blandit in, rutrum quis, semper pulvinar, enim. Nullam varius congue risus.
Vivamus sollicitudin, metus ut interdum eleifend, nisi tellus pellentesque elit, tristique
accumsan eros quam et risus. Suspendisse libero odio, mattis sit amet, aliquet eget,
hendrerit vel, nulla. Sed vitae augue. Aliquam erat volutpat. Aliquam feugiat vulputate nisl.
Suspendisse quis nulla pretium ante pretium mollis. Proin velit ligula, sagittis at, egestas a,
pulvinar quis, nisl.
Pellentesque sit amet lectus. Praesent pulvinar, nunc quis iaculis sagittis, justo quam
lobortis tortor, sed vestibulum dui metus venenatis est. Nunc cursus ligula. Nulla facilisi.
Phasellus ullamcorper consectetur ante. Duis tincidunt, urna id condimentum luctus, nibh
ante vulputate sapien, id sagittis massa orci ut enim. Pellentesque vestibulum convallis
sem. Nulla consequat quam ut nisl. Nullam est. Curabitur tincidunt dapibus lorem. Proin
velit turpis, scelerisque sit amet, iaculis nec, rhoncus ac, ipsum. Phasellus lorem arcu,
feugiat eu, gravida eu, consequat molestie, ipsum. Nullam vel est ut ipsum volutpat
feugiat. Aenean pellentesque.
In mauris. Pellentesque dui nisl, iaculis eu, rhoncus in, venenatis ac, ante. Ut odio justo,
scelerisque vel, facilisis non, commodo a, pede. Cras nec massa sit amet tortor volutpat
varius. Donec lacinia, neque a luctus aliquet, pede massa imperdiet ante, at varius lorem
pede sed sapien. Fusce erat nibh, aliquet in, eleifend eget, commodo eget, erat. Fusce
consectetur. Cras risus tortor, porttitor nec, convallis semper, eros. Fusce
volutate ipsum a mauris. Phasellus mollis. Curabitur sed urna. Aliquam nec sapien non
nibh pulvinar convallis. Vivamus facilisis augue quis quam. Proin cursus aliquet metus.
Suspendisse lacinia. Nulla at tellus ac turpis eleifend scelerisque. Maecenas a pede vitae
enim commodo interdum. Donec odio. Sed sollicitudin dui vitae justo.
Morbi elit nunc, facilisis a, mollis a, molestie at, lectus. Suspendisse eget mauris eu tellus
molestie cursus. Duis ut magna at justo dignissim condimentum. Cum sociis natoque
penatibus et magnis dis parturient montes, nascetur ridiculus mus. Vivamus varius. Ut sit
amet diam suscipit mauris ornare aliquam. Sed varius. Duis arcu. Etiam tristique massa
eget dui. Phasellus congue. Aenean est erat, tincidunt eget, venenatis quis, commodo at,
quam.
```

Si aplicamos esta librería a nuestro ejemplo con la ficha técnica del auto, verás que igualmente hay algunas diferencias en el texto extraído.

## PdfReader (pypdf)

```
Comandos + Código + Texto Ejecutar todas
[32] reader = PdfReader("ficha_A1.pdf")
WARNING:pypdf._reader:Ignoring wrong pointing object 12 0 (offset 0)
WARNING:pypdf._reader:Ignoring wrong pointing object 46 0 (offset 0)

[33] page = reader.pages[0]
print(page.extract_text())

Ficha técnica
A1 Sportback 2024
Motorización A1 5B 35 TFSI Ego A1 5B 40 TFSI 5 line
Cilindrada 1.5 l (1,498 cm3) 2.0 l (1,984 cm3)
Motor 4 cil. en línea, TFSI 4 cil. en línea, TFSI
Potencia 150 hp / 5,000- 6,000 rpm 200 hp / 4,400-6,000 rpm
Torque 250 Nm / 1,500 -3,500 rpm 320 Nm/1,500 - 4,400 rpm
Tracción delantera delantera
Transmisión 5 tronic 7 Vel. 5 tronic 6 Vel.
Velocidad máxima 222 km/ hr 235km/hr
Aceleración 0-100 km/hr 7.7 s 6.5 s
Rendimiento de combustible (ciudad / carretera / combinado) 14.8/ 20.6/ 16.9 km/13.7/ 19.4/ 15.8 km/l
Norma de emisión de gases EU6
Emisiones de CO2 (ciudad / carretera / combinado) 159.1/ 114.8/ 138.8 gCO2/km 171.2/ 121.2/ 148.7 gCO2/km
Dimensiones Largo 4029 mm 4029 mm
Ancho 1740 mm 1740 mm
Alto 1433 mm 1433 mm
Distancia entre ejes 2563 mm 2563 mm
Peso en vacío (con conductor) 1,240 kg 1,335 kg
Capacidad del maletero 335 l 335 l
Capacidad del tanque de combustible 40 l 40 l
Número de puertas 5 5
Sistemas de Asistencia y Seguridad
Airbags delanteros con interruptor para desconectar el airbag del acompañante S
Airbags laterales delanteros con airbag de cabeza S S
Alarma antirrobo S S
Anclaje de fijación para asientos de niños para asientos traseros exteriores S S
Asistente de arranque en pendientes (Audi Hold Assist) S S
Asistente de estacionamiento trasero (sensores traseros) S -
Asistente de estacionamiento plus (sensores delanteros y traseros) O S
Cámara de reversa O O
Audi Park Assist O O
Audi Drive Select S S
Bielros de seguridad S S
Triángulo de seguridad S S
```

```
Comandos + Código + Texto Ejecutar todas
[43] doc = pymupdf.open("ficha_A1.pdf")
page = doc.load_page(0)
print(page.get_text())

Ficha técnica
A1 Sportback 2024
Motorización
A1 5B 35 TFSI
Ego
A1 5B 40 TFSI
5 line
Cilindrada
1.5 l (1,498 cm3)
2.0 l (1,984 cm3)
Motor
4 cil. en línea, TFSI
4 cil. en línea, TFSI
Potencia
150 hp / 5,000- 6,000 rpm
200 hp / 4,400-6,000 rpm
Torque
250 Nm / 1,500 -3,500 rpm
320 Nm/1,500 - 4,400 rpm
Tracción
delantera
delantera
Transmisión
5 tronic 7 Vel.
5 tronic 6 Vel.
Velocidad máxima
222 km/ hr
235km/hr
Aceleración 0-100 km/hr
7.7 s
6.5 s
Rendimiento de combustible (ciudad / carretera / combinado)
14.8/ 20.6/ 16.9 km/
13.7/ 19.4/ 15.8 km/l
Norma de emisión de gases
EU6
Emisiones de CO2 (ciudad / carretera / combinado)
159.1/ 114.8/ 138.8 gCO2/km
171.2/ 121.2/ 148.7 gCO2/km
```

## Extracción de texto con PDFMiner

Una tercera biblioteca para extraer texto es a través de `pdfminer`, tal como las librerías anteriores, instalamos, importamos y extraemos el texto de ambos PDF.

### PDF “sample”

Bloques de código:

```
!pip install pdfminer.six

from pdfminer.high_level
import extract_pages,
extract_text

text= extract_text("sample.
pdf")

print(text)
```

### PDF “ficha\_A\_A1”

```
from pdfminer.high_level
import extract_pages,
extract_text

text= extract_text("ficha_A_
A1.pdf")
```

Salida:

The image shows two side-by-side Jupyter Notebook interfaces. The left notebook, titled 'sample', contains code to install 'pdfminer.six' and extract text from 'sample.pdf'. The output shows a large block of Lorem Ipsum text. The right notebook, titled 'ficha\_A\_A1', contains code to extract text from 'ficha\_A\_A1.pdf'. The output shows a technical specification for a car, including 'Ficha técnica', 'A1 Sportback 2024', 'Motorización', and various engine and performance details.

**Left Notebook (sample):**

```
[ ] !pip install pdfminer.six
from pdfminer.high_level import extract_pages, extract_text

[ ] text= extract_text("sample.pdf")
print(text)
```

**Right Notebook (ficha\_A\_A1):**

```
[ ] from pdfminer.high_level import extract_pages, extract_text

[ ] text= extract_text("ficha_A_A1.pdf")

[ ] print(text)
```

Ahora es tu turno de poner en práctica lo aprendido en este subtema con tus propios archivos, recuerda que, dependiendo del tipo de archivos que tengas a tu disposición deberás usar las diferentes bibliotecas vistas en este tema para la obtención de un mejor resultado.

## | Glosario

**Bibliotecas (Librerías).** Conjuntos de funciones predefinidas que permiten realizar tareas específicas sin necesidad de programar desde cero. En el contexto del subtema se usan para extraer texto de PDF.

**PyPDF.** Biblioteca de Python especializada en manipular archivos PDF. Permite leer, extraer texto y metadatos.

- `PdfReader`: Clase de PyPDF que permite leer un archivo PDF.
- `pages`: Atributo que contiene las páginas del PDF.
- `extract_text()`: Método que extrae el texto de una página específica.

**PyMuPDF (fitz).** Otra biblioteca para trabajar con PDFs, conocida por su alto rendimiento en la extracción de texto y gráficos.

- `pymupdf.open()`: Función para abrir un archivo PDF.
- `load_page()`: Método para cargar una página específica del PDF.
- `get_text()`: Método para extraer el texto de una página.

**PDFMiner.** Biblioteca enfocada en extraer texto, imágenes y otros elementos de PDFs, especialmente útil para documentos complejos.

- `PDFParser`: Clase que analiza el contenido del PDF.
- `PDFDocument`: Clase que almacena la estructura del documento.
- `PDFPageInterpreter`: Clase que procesa el contenido de las páginas.

## | Material adicional


pdf2image. (s.f.). *pdf2image documentation* [Documentación de pdf2image]. Recuperado el 30 de marzo de 2024, de <https://pdf2image.readthedocs.io/en/latest/index.html>

Tabula-py. (s.f.). *Tabula-py documentation* [Documentación de Tabula-py]. Recuperado el 30 de marzo de 2025, de <https://tabula-py.readthedocs.io/en/latest/tabula.html>

Vine, J. (s.f.). *pdfplumber* [pdfplumber]. GitHub. Recuperado el 30 de marzo de 2024, de <https://github.com/jsvine/pdfplumber>

YouTube. (s.f.). [Video] *Working with PDFs in Python* [[Video] Trabajando con PDFs en Python]. Recuperado el 30 de marzo de 2025, de <https://www.youtube.com/watch?v=w2r2Bg42UPY>

**Nota:** Los enlaces a las páginas web incluidos en esta bibliografía fueron consultados y verificados por última vez el 30 de marzo del 2025 y su disponibilidad depende del autor.





## | Bibliografía

FreeCodeCamp. (s.f.). *Extract data from PDF files with Python* [Extraer datos de archivos PDF con Python]. Recuperado el 30 de marzo de 2025, de <https://www.freecodecamp.org/news/extract-data-from-pdf-files-with-python/>

PyMuPDF. (s.f.). *PyMuPDF documentation* [Documentación de PyMuPDF]. Recuperado el 30 de marzo de 2025, de <https://pymupdf.readthedocs.io/en/latest/>

PyMuPDF. (s.f.). *PyMuPDF tutorial* [Tutorial de PyMuPDF]. Recuperado el 30 de marzo de 2025, de <https://pymupdf.readthedocs.io/en/latest/tutorial.html>

PyMuPDF. (s.f.). *Recipes for working with images* [Recetas para trabajar con imágenes]. Recuperado el 30 de marzo de 2025, de <https://pymupdf.readthedocs.io/en/latest/recipes-images.html>

PyPDF. (s.f.). *PyPDF documentation* [Documentación de PyPDF]. Recuperado el 30 de marzo de 2025, de <https://pypdf.readthedocs.io/en/stable/>

PyPDF. (s.f.). *Extracting images from PDFs* [Extracción de imágenes de PDFs]. Recuperado el 30 de marzo de 2025, de <https://pypdf.readthedocs.io/en/stable/user/extract-images.html>

**Nota:** Los enlaces a las páginas web incluidos en esta bibliografía fueron consultados y verificados por última vez el 30 de marzo del 2025 y su disponibilidad depende del autor.