



Extraer tablas de Documentos PDF

Como vimos en los ejemplos anteriores, cuando tenemos puro texto, las librerías revisadas pueden ser muy útiles, pero como se comentó previamente, muchas veces los documentos PDF a los que tenemos acceso son reportes de algún tipo de tabla o información proveniente de alguna base de datos, donde la información está presentada en forma de tabla.

En este recurso trabajaremos con una librería de Python llamada **tabula**, la cual está basada en **tabula-java** y permite extraer tablas contenidas en archivos PDF para convertirlas en un **dataFrame**, lo que facilita su manipulación en Python. Para ponerla en práctica, utilizaremos un archivo denominado “sb2”, que contiene información sobre las ediciones del Super Tazón, uno de los eventos deportivos más importantes de la actualidad. Este archivo, que puedes descargar desde los archivos adjuntos de la plataforma, fue obtenido de Wikipedia en marzo de 2025, específicamente desde la página https://es.wikipedia.org/wiki/Anexo:Campeones_del_Super_Bowl. Si deseas consultar la fuente original, copia y pega la URL en tu navegador.

Para empezar, instalamos dicha biblioteca. Además de realizar los *imports* necesarios.

```
!pip install tabula-py[jpype]
import tabula
import pandas as pd
```

A continuación, leemos el archivo “sb2”, que contiene la tabla con la información de los encuentros del *Super Bowl*.


```
tablas = tabula.read_pdf("sb2.pdf",
    pages="all",
    multiple_tables=True,)
```

En este caso, después del nombre del archivo tenemos los parámetros `pages=all` para indicarle que tome en cuenta todas las páginas del documento, en el parámetro `multiple_tables` le pasamos el valor `False`, porque queremos que interprete todas las páginas como parte de la misma tabla, si le pasáramos el valor `True`, `read_pdf` nos regresaría una lista de varios *dataFrames*, uno por cada hoja.

`read_pdf` nos regresa una lista con un solo *dataframe*, así que lo asignamos a la variable `df` e imprimimos el resultado, mediante la siguiente instrucción.

```
df = tablas[0] print(df.head(10))
```

Al inspeccionar el contenido de nuestro *DataFrame* podemos notar que aparecen algunos caracteres no deseados. Por ejemplo, en las fechas, que están distribuidas en varias filas, podemos encontrar el carácter `\r`. También podemos ver que algunos nombres de equipos, estadios o ciudades incluyen saltos de línea o están cortados, además, algunos números están rodeados de paréntesis en determinados valores.



```
[ ] df = tablas[0]
print(df.head(10))
```

```

Edición      Fecha      Ganador Marcador \
0      I  15 de\renero\rde 1967      Green Bay\rPackers 35 - 10
1      II 14 de\renero\rde 1968      Green Bay\rPackers (2) 33 - 14
2      III 12 de\renero\rde 1969      New York Jets 16 - 7
3      IV 11 de\renero\rde 1970      Kansas City\rChiefs 23 - 7
4      V 17 de\renero\rde 1971      Baltimore Colts 16 - 13
5      VI 16 de\renero\rde 1972      Dallas Cowboys 24 - 3
6      VII 14 de\renero\rde 1973      Miami Dolphins 14 - 7
7      VIII 13 de\renero\rde 1974      Miami Dolphins\r(2) 24 - 7
8      IX 12 de\renero\rde 1975      Pittsburgh\rSteelers 16 - 6
9      X 18 de\renero\rde 1976      Pittsburgh\rSteelers (2) 21 - 17

Perdedor      Estadio \
0      Kansas City\rChiefs      Los Angeles Memorial\rColiseum
1      Oakland Raiders      Miami Orange Bowl
2      Baltimore Colts      Miami Orange Bowl (2)
3      Minnesota\rVikings      Tulane Stadium
4      Dallas Cowboys      Miami Orange Bowl (3)
5      Miami Dolphins      Tulane Stadium (2)
6      Washington\rRedskins      Los Angeles Memorial\rColiseum (2)
7      Minnesota\rVikings (2)      Rice Stadium
8      Minnesota\rVikings (3)      Tulane Stadium (3)
9      Dallas Cowboys\r(2)      Miami Orange Bowl (4)

Ciudad
0      Los Angeles, California
1      Miami, Florida
2      Miami, Florida (2)
3      Nueva Orleans,\rLuisiana
4      Miami, Florida (3)

```

Para limpiar nuestro *dataframe* de los caracteres no deseados, reemplazándolos con un espacio en blanco, y eliminar los números entre paréntesis, emplearemos el siguiente bloque de código.

```

df['Fecha'] = df['Fecha'].str.replace('\r', ' ')

df['Ganador'] = df['Ganador'].str.replace('\r', ' ').str.rstrip(' (0123456789) ')

df['Marcador'] = df['Marcador'].str.replace(r'\[.*\]', '',
regex=True)

```

```
df['Perdedor'] = df['Perdedor'].str.replace('\r', ' ').str.rstrip(' (0123456789)')
```

```
df['Estadio'] = df['Estadio'].str.replace('\r', ' ').str.rstrip(' (0123456789)')
```

```
df['Ciudad'] = df['Ciudad'].str.replace('\r', ' ').str.rstrip(' (0123456789)')
```

Compilamos e imprimimos el resultado empleando la siguiente instrucción, donde podremos apreciar la corrección.

```
print(df.head(10))
```

```
[ ] print(df.head(10))
```

	Edición	Fecha	Ganador	Marcador	\
0	I	15 de enero de 1967	Green Bay Packers	35 - 10	
1	II	14 de enero de 1968	Green Bay Packers	33 - 14	
2	III	12 de enero de 1969	New York Jets	16 - 7	
3	IV	11 de enero de 1970	Kansas City Chiefs	23 - 7	
4	V	17 de enero de 1971	Baltimore Colts	16 - 13	
5	VI	16 de enero de 1972	Dallas Cowboys	24 - 3	
6	VII	14 de enero de 1973	Miami Dolphins	14 - 7	
7	VIII	13 de enero de 1974	Miami Dolphins	24 - 7	
8	IX	12 de enero de 1975	Pittsburgh Steelers	16 - 6	
9	X	18 de enero de 1976	Pittsburgh Steelers	21 - 17	

	Perdedor	Estadio	\
0	Kansas City Chiefs	Los Angeles Memorial Coliseum	
1	Oakland Raiders	Miami Orange Bowl	
2	Baltimore Colts	Miami Orange Bowl	
3	Minnesota Vikings	Tulane Stadium	
4	Dallas Cowboys	Miami Orange Bowl	
5	Miami Dolphins	Tulane Stadium	
6	Washington Redskins	Los Angeles Memorial Coliseum	
7	Minnesota Vikings	Rice Stadium	
8	Minnesota Vikings	Tulane Stadium	
9	Dallas Cowboys	Miami Orange Bowl	

	Ciudad
0	Los Ángeles, California
1	Miami, Florida
2	Miami, Florida
3	Nueva Orleans, Luisiana
4	Miami, Florida
5	Nueva Orleans, Luisiana
6	Los Ángeles, California
7	Houston, Texas
8	Nueva Orleans, Luisiana
9	Miami, Florida

Finalizamos mostrando el *dataframe* limpio con el que podremos trabajar.

[] df

	Edición	Fecha	Ganador	Marcador	Perdedor	Estadio	Ciudad
0	I	15 de enero de 1967	Green Bay Packers	35 - 10	Kansas City Chiefs	Los Angeles Memorial Coliseum	Los Ángeles, California
1	II	14 de enero de 1968	Green Bay Packers	33 - 14	Oakland Raiders	Miami Orange Bowl	Miami, Florida
2	III	12 de enero de 1969	New York Jets	16 - 7	Baltimore Colts	Miami Orange Bowl	Miami, Florida
3	IV	11 de enero de 1970	Kansas City Chiefs	23 - 7	Minnesota Vikings	Tulane Stadium	Nueva Orleans, Luisiana
4	V	17 de enero de 1971	Baltimore Colts	16 - 13	Dallas Cowboys	Miami Orange Bowl	Miami, Florida
5	VI	16 de enero de 1972	Dallas Cowboys	24 - 3	Miami Dolphins	Tulane Stadium	Nueva Orleans, Luisiana
6	VII	14 de enero de 1973	Miami Dolphins	14 - 7	Washington Redskins	Los Angeles Memorial Coliseum	Los Ángeles, California
7	VIII	13 de enero de 1974	Miami Dolphins	24 - 7	Minnesota Vikings	Rice Stadium	Houston, Texas
8	IX	12 de enero de 1975	Pittsburgh Steelers	16 - 6	Minnesota Vikings	Tulane Stadium	Nueva Orleans, Luisiana
9	X	18 de enero de 1976	Pittsburgh Steelers	21 - 17	Dallas Cowboys	Miami Orange Bowl	Miami, Florida
10	XI	9 de enero de 1977	Oakland Raiders	32 - 14	Minnesota Vikings	Rose Bowl	Pasadena, California
11	XII	15 de enero de 1978	Dallas Cowboys	27 - 10	Denver Broncos	Louisiana Superdome	Nueva Orleans, Luisiana
12	XIII	21 de enero de 1979	Pittsburgh Steelers	35 - 31	Dallas Cowboys	Miami Orange Bowl	Miami, Florida
13	XIV	20 de enero de 1980	Pittsburgh Steelers	31 - 19	Los Angeles Rams	Rose Bowl	Pasadena, California
14	XV	25 de enero de 1981	Oakland Raiders	27 - 10	Philadelphia Eagles	Superdome	Nueva Orleans, Luisiana
15	XVI	24 de enero de 1982	San Francisco 49ers	26 - 21	Cincinnati Bengals	Pontiac Silverdome	Pontiac, Michigan
16	XVII	30 de enero de 1983	Washington Redskins	27 - 17	Miami Dolphins	Rose Bowl	Pasadena, California
17	XVIII	22 de enero de 1984	Los Angeles Raiders	38 - 9	Washington Redskins	Tampa Stadium	Tampa, Florida
18	XIX	20 de enero de 1985	San Francisco 49ers	38 - 16	Miami Dolphins	Stanford Stadium	Stanford, California
19	XX	26 de enero de 1986	Chicago Bears	46 - 10	New England Patriots	Louisiana Superdome	Nueva Orleans, Luisiana

| Glosario

Tabula. Biblioteca de Python basada en tabula-java que permite extraer tablas de archivos PDF y convertirlas en estructuras de datos como DataFrames de pandas.

- `read_pdf()` : Función de Tabula que lee tablas de un PDF y las devuelve como una lista de DataFrames.

Parámetros clave:

- `pages="all"` : Extrae tablas de todas las páginas.
- `multiple_tables=True/False` : Indica si el PDF contiene múltiples tablas independientes.

Caracteres especiales. Símbolos o formatos no estándar en el texto extraído (ej. saltos de línea `\r`, corchetes `[ ]`), que requieren procesamiento adicional.

PyMuPDF (fitz). Biblioteca alternativa para extraer texto y tablas de PDFs, aunque menos especializada que Tabula para este propósito.

OCR (Reconocimiento Óptico de Caracteres). Tecnología para extraer texto de imágenes o PDFs escaneados. *No se usa directamente en este tema, pero es relevante para PDFs no editables.*

Nota: Los enlaces a las páginas web incluidos en esta bibliografía fueron consultados y verificados por última vez el 30 de marzo del 2025 y su disponibilidad depende del autor.

| Material adicional


pdf2image. (s.f.). *pdf2image documentation* [Documentación de pdf2image]. Recuperado el 30 de marzo de 2024, de <https://pdf2image.readthedocs.io/en/latest/index.html>

Tabula-py. (s.f.). *Tabula-py documentation* [Documentación de Tabula-py]. Recuperado el 30 de marzo de 2025, de <https://tabula-py.readthedocs.io/en/latest/tabula.html>

Vine, J. (s.f.). *pdfplumber* [pdfplumber]. GitHub. Recuperado el 30 de marzo de 2024, de <https://github.com/jsvine/pdfplumber>

YouTube. (s.f.). [Video] *Working with PDFs in Python* [[Video] Trabajando con PDFs en Python]. Recuperado el 30 de marzo de 2025, de <https://www.youtube.com/watch?v=w2r2Bg42UPY>

Nota: Los enlaces a las páginas web incluidos en esta bibliografía fueron consultados y verificados por última vez el 30 de marzo del 2025 y su disponibilidad depende del autor.



| Bibliografía

FreeCodeCamp. (s.f.). *Extract data from PDF files with Python* [Extraer datos de archivos PDF con Python]. Recuperado el 30 de marzo de 2025, de <https://www.freecodecamp.org/news/extract-data-from-pdf-files-with-python/>

PyMuPDF. (s.f.). *PyMuPDF documentation* [Documentación de PyMuPDF]. Recuperado el 30 de marzo de 2025, de <https://pymupdf.readthedocs.io/en/latest/>

PyMuPDF. (s.f.). *PyMuPDF tutorial* [Tutorial de PyMuPDF]. Recuperado el 30 de marzo de 2025, de <https://pymupdf.readthedocs.io/en/latest/tutorial.html>

PyMuPDF. (s.f.). *Recipes for working with images* [Recetas para trabajar con imágenes]. Recuperado el 30 de marzo de 2025, de <https://pymupdf.readthedocs.io/en/latest/recipes-images.html>

PyPDF. (s.f.). *PyPDF documentation* [Documentación de PyPDF]. Recuperado el 30 de marzo de 2025, de <https://pypdf.readthedocs.io/en/stable/>

PyPDF. (s.f.). *Extracting images from PDFs* [Extracción de imágenes de PDFs]. Recuperado el 30 de marzo de 2025, de <https://pypdf.readthedocs.io/en/stable/user/extract-images.html>

Nota: Los enlaces a las páginas web incluidos en esta bibliografía fueron consultados y verificados por última vez el 30 de marzo del 2025 y su disponibilidad depende del autor.